

ESQUEMA DEFINITIVO DEL TFG

(VERSIÓN FINAL)

Título propuesto: *Component-Wise Adversarial Robustness in Interpretable Neural Networks: Ablation, Latent Dynamics, and Architectural Dependence.*

Capítulo 1. Introducción (EMBUDOOOOO)

- **Contexto:** Deep Learning combina alta precisión con dos problemas abiertos: vulnerabilidad adversarial y falta de interpretabilidad.
- **Debate:** Algunos trabajos sugieren una relación entre robustez e interpretabilidad, pero esta relación no es universal.
- **Problema:** Los modelos interpretables por diseño permiten inspeccionar partes internas, pero no garantizan robustez adversarial.
- **Huevo:** El adversarial fine-tuning puede mejorar la robustez, pero no explica qué componente interno absorbe esa robustez ni si la explicación sigue siendo fiable.
- **Objetivo:** Construir una auditoría component-wise para estudiar qué se rompe, qué se robustece y si el patrón depende de la arquitectura.
- **Preguntas de Investigación (RQs):**
 - RQ1 (Diagnóstico): ¿Cómo se degrada internamente un modelo interpretable bajo ataque adversarial, y puede colapsar su explicación antes que su predicción?
 - RQ2 (Intervención): En arquitecturas basadas en prototipos, ¿qué componente absorbe principalmente la robustez tras el adversarial fine-tuning?
 - RQ3 (Mecánica): ¿Qué dinámicas del espacio latente explican la adquisición de robustez y el posible aumento del ICR?
 - RQ4 (Generalización): ¿El mecanismo de robustez es universal o depende de la arquitectura?
- **Contribuciones:**
 - A formal component-wise evaluation framework based on prediction margins, prototype margins, internal drift metrics, empirical PGD safe radii, ICR, and cohesion ratios.
 - Estudio ablativo que muestra la criticidad de la representación latente (autoencoder) en B30/ProtoVAE.
 - Análisis geométrico (cohesión, dinámicas de entrenamiento y trayectorias de ataque) y análisis de un posible fenómeno de desincronización encoder-prototipo observado en FT-E.
 - Evidencia de dependencia arquitectónica del mecanismo de robustez contrastando con ProtoVAE/SENN.

Capítulo 2. Marco Teórico y Estado del Arte

- **2.1 Deep Learning for Image Classification**
 - Breve explicación de redes neuronales profundas.

- CNNs como arquitectura habitual en visión.
 - Representaciones internas y espacio latente.
- **2.2 Interpretability in Deep Learning**
 - Interpretabilidad post-hoc vs interpretabilidad intrínseca.
 - Por qué no basta con que el modelo acierte: también queremos entender su razonamiento.
 - Explicaciones visuales, prototipos y conceptos.
- **2.3 Interpretable Architectures Used in this Thesis**
 - PrototypeDL / B30.
 - ProtoVAE.
 - SENN.
 - Aquí explicas por qué estos modelos son buenos para tu auditoría component-wise.
 - Qué componente interpretable tiene cada arquitectura:
 - autoencoder/prototipos/clasificador en B30 y ProtoVAE;
 - conceptizer/parametrizer/aggregator en SENN.
- **2.4 Adversarial Robustness**
 - Ejemplos adversarios.
 - Threat model $\backslash(L_infty)$.
 - PGD.
 - Adversarial training.
 - AutoAttack y gradient masking solo como contexto, sin entrar aún en tu anomalía.
- **2.5 Robustness and Interpretability: Relation and Tension**
 - Algunos trabajos sugieren que robustez e interpretabilidad pueden estar relacionadas.
 - Pero no es una ley universal.
 - Interpretabilidad por diseño no implica automáticamente robustez.
 - Aquí abres el hueco que justifica tu TFG.
- **2.6 Previous Work and Positioning of this Thesis**
 - Cuadro comparativo estricto. Silvia (balanceo, ataques EU/ET)
 - Jon (loss ADVL, freezing básico sin métricas internas)
 - Yo (framework matemático, ablación paramétrica sistemática, análisis geométrico, anomalía FT-E y validación inter-arquitecturas).

Capítulo 3. Metodología y Framework de Evaluación

- **Planteamiento:** Definir matemáticamente el entorno de prueba y las herramientas de auditoría ("el bisturí") que se usarán a lo largo del TFG.
- **3.1 Modelos y Dataset:** MNIST sobre B30, ProtoVAE y SENN.
- **3.2 Threat Model:** PGD L_{inf} , , evaluado sobre un sweep de epsilons. Para la estimación de r-PGD, el sweep se usa como bracket inicial y posteriormente se refina mediante binary search. AutoAttack default.
- **3.3 Métricas Internas (El Bisturí):** Definición matemática formal:
 - *Prototype Margin:* (m_{proto})
 - *Prediction Margin:* (m_{pred})
 - *Derivas Espaciales:* (R_{enc} , R_{dec} , R_{mu} , R_{sigma} , $R_{concept}$, R_{param})

- *Estimated empirical PGD safe radius: $r\text{-PGD}(x)$ calculado sobre muestras clean-correct mediante sweep + binary search.*
- **3.4 Interpretability Collapse Rate (ICR):**
 - Indicador por muestra $I_ICR(x_i)$ detecta si existe algún e donde la explicación prototípica falla mientras la predicción sigue siendo correcta.
 - Tasa global: ICR promedio de $I_ICR(x_i)$ sobre el test set.
- **3.5 Cohesion Ratio:** Para evaluar si el fine-tuning preserva la organización semántica relativa entre muestras y prototipos.
- **3.6 Protocolo Ablativo:**
 - Definición de escenarios (FT-0, FT-1, FT-2, FT-3, FT-E, FT-E-M). TABLA:

Model	Frozen components	Trainable components	Purpose
FT-0			
FT-1			
FT-2			
FT-3			
FT-E			
FT-E-M			

Capítulo 4. — Diagnóstico de la Fragilidad Base

- **Planteamiento:** Auditar el modelo B30 limpio bajo ataque PGD para establecer una línea base de cómo se degrada la red internamente.
- **Resultados:**
 - **Paneles de degradación:**
 - Semántica: Curvas de m_proto vs m_pred bajo e .
 - Estructura Interna: Curva de R_enc (eje Y: Ratio de deformación)
 - Estructura Visual: Curva de R_dec (eje Y: Error absoluto L_2).
 - Distribución del $r\text{-PGD}(x)$ estimado y resumen mediante media y mínimo (histograma).
- **Conclusión:** Cálculo del ICR. El ICR permite cuantificar casos en los que la explicación prototípica falla mientras la predicción aún sigue siendo correcta.

Capítulo 5. — Intervención: Ablación Adversarial en B30

- **Planteamiento:** Aislar componentes congelándolos durante el fine-tuning para identificar de forma unívoca qué bloque absorbe la robustez.
- **Resultados:**
 - Gráficos o Tabla maestra de *Clean Acc* y caída de métricas (m_proto , m_pred , R_enc , R_dec) para FT-0, FT-1, FT-2, FT-3, FT-E y FT-E-M.
 - Cálculo de ICR
- **Conclusión:** En B30, congelar el autoencoder reduce fuertemente la robustez obtenida por fine-tuning, mientras que entrenarlo incluso en solitario puede sostener gran parte de la defensa. La robustez en B30 es altamente dependiente de la representación. Además, se observa un posible trade-off empírico: algunos modelos más robustos presentan mayor ICR, lo que motiva el análisis mecánico del Capítulo 6.
 - m_pred y m_proto de B30 va hacia 0 porque el ejemplo se aleja tanto que al final es la misma distancia.

Capítulo 6. — Dinámicas del Espacio Latente y Explicación Mecánica

- **Planteamiento:** Analizar cuantitativa y visualmente cómo el fine-tuning modifica el espacio latente y cómo estos cambios pueden explicar la robustez observada.
- **6.1 Ratio de Cohesión Invariante (Matemática):** Tabla con el ratio de cohesión para evaluar si el fine-tuning preserva la estructura semántica relativa entre clases.

- **Conclusión:** Los resultados sugieren que el fine-tuning puede ensanchar o reescalar los clústeres sin eliminar completamente la separación semántica entre clases.
- **6.2 Evolución del Espacio Latente (Visualización):** Visualización PCA de muestras y prototipos usando una misma base de proyección. Comparación Base vs FT-0 y Base vs FT-E-M. Se usarán muestras clean y atacadas con PGD. Muestra cómo el encoder reorganiza los clústeres y cómo se adaptan los prototipos. (El posible solapamiento visual de prototipos en 2D se interpretará con cautela, ya que puede deberse a la proyección PCA).
 - Para comparar de forma consistente la evolución del espacio latente entre distintas estrategias de fine-tuning, se ajusta una única base PCA utilizando las representaciones latentes limpias de todos los checkpoints y variantes de una misma arquitectura. Posteriormente, cada variante se proyecta sobre esta misma base fija y se exporta como una figura independiente. De este modo, las diferencias observadas entre variantes reflejan cambios reales en el espacio latente y no variaciones debidas a sistemas PCA distintos.
 - **Conclusión:** Evidencia visual consistente con el ensanchamiento del espacio latente y la justificación topológica del aumento del ICR (más ancho posible más fallo).
- **6.3 Trayectorias PGD en PCA y punto final de AutoAttack sobre las mismas muestras:** Proyección PCA de los pasos iterativos de PGD. Contraste visual en el modelo. AutoAttack sirve como **punto de validación fuerte** del fallo final.
 - Para mantener la comparabilidad con el análisis anterior, las trayectorias adversariales se proyectan sobre la misma base PCA global ajustada con representaciones limpias. Las muestras adversariales no se utilizan para ajustar el PCA, sino únicamente para visualizar su desplazamiento dentro del espacio latente aprendido.
 - Además de la visualización PCA, se calculan métricas cuantitativas en el espacio latente original. El desplazamiento final PGD mide la distancia entre la representación limpia y la adversarial final; el desplazamiento AutoAttack mide el mismo efecto con un ataque más fuerte; y la longitud de trayectoria PGD mide el recorrido total de la representación latente durante el ataque. Estas métricas permiten complementar la interpretación visual con una medida directa del cambio inducido por el ataque.
 - Sea z_i^0 la representación latente limpia de la muestra i , z_i^T la representación latente tras el último paso de PGD, z_i^t la representación latente en el paso t de PGD, z_i^{AA} la representación latente final generada por AutoAttack, N el número de muestras y T el número de iteraciones PGD.
 - Desplazamiento final PGD:
 - $D_{PGD} = (1 / N) * \sum_{i=1}^N || z_i^T - z_i^0 ||_2$
 - Esta métrica mide cuánto se aleja, en promedio, la representación latente adversarial final obtenida con PGD respecto a la representación limpia.
 - Desplazamiento AutoAttack:
 - $D_{AA} = (1 / N) * \sum_{i=1}^N || z_i^{AA} - z_i^0 ||_2$
 - Esta métrica mide el desplazamiento medio producido por AutoAttack respecto a la representación latente limpia.
 - Longitud de trayectoria PGD:

- $L_{PGD} = (1 / N) * \sum_{i=1}^N \sum_{t=1}^T || z_i^t - z_i^{t-1} ||_2$
- Esta métrica mide la longitud media del recorrido de la representación latente durante todo el ataque PGD, acumulando los desplazamientos entre pasos consecutivos.
- **Conclusión:** En el modelo Base la muestra cruza la frontera; en FT-0 queda contenida. En las muestras visualizadas, PGD no parece seguir una transición semántica clara hacia otra clase, sino que se desplaza siguiendo direcciones de pérdida adversaria.

Capítulo 7. — Generalización: ¿Es un patrón universal?

- **Planteamiento:** Replicar la auditoría en otras arquitecturas para determinar si la robustez del encoder es una ley general o depende del diseño de la red.
- **7.1 ProtoVAE:**
 - Tabla o graficos de ablación (Accuracies) y extracción de métricas de homologas a B30 (m_{proto} , m_{pred} , R_{dec} , R_{μ} (equivalente a R_{enc}) y R_{σ})
 - Comparativa directa de la supervivencia ($E[r_{PGD}]$ y $\min r_{PGD}$)
 - Cálculo y debate del ICR frente a B30.
 - **Conclusiones de ProtoVAE:**
 - Los resultados reproducen parcialmente el patrón observado en B30: la representación latente vuelve a ser un componente central para la robustez.
 - La regularización variacional por KL es consistente con una geometría latente más suave y puede ayudar a explicar la ausencia de la anomalía tipo FT-E. No se interpreta como una garantía formal contra gradient masking. (la curva anómala en "U" no ocurre aquí).
 - A epsilons extremos, el aumento de R_{σ} puede interpretarse como un posible mecanismo de compensación mediante incertidumbre latente.
- **7.2 SENN:**
 - Tabla o graficos de ablación (Accuracies) y métricas adaptadas (m_{pred} , $R_{concept}$ y R_{param})
 - **Conclusiones de SENN:**
 - El patrón observado en B30/ProtoVAE no se reproduce directamente en SENN. Congelar el extractor de características (Conceptizer) apenas penaliza, pero congelar el asignador de pesos (Parametrizer) destruye la robustez.
 - Al congelar el Parametrizer bajo ataque, la deriva del Conceptizer ($R_{concept}$) explota, sugiriendo que la red intenta compensar un módulo de decisión no adaptable mediante cambios en la representación conceptual.
- **7.3 Conclusión Final de la Generalización:**

- **Conclusión:** Los resultados sugieren que el componente responsable de absorber la robustez depende de la arquitectura. La robustez parece recaer en el componente que, según la arquitectura, tiene mayor capacidad para absorber, filtrar o reponderar la perturbación: el autoencoder en B30/ProtoVAE y el parametrizer en SENN.

Capítulo 8. Estudio de Caso: La Anomalía FT-E y Diagnóstico de Posible Ofuscación de Gradientes

- **Planteamiento:** Aislar el comportamiento anómalo del modelo FT-E para realizar un análisis forense sobre los riesgos de la falsa robustez.
- **8.1 Identificación:** Curva no monótona (en "U") de accuracy vs epsilon
- **8.2 Diagnóstico:**
 - Sanity checks del pipeline: escala de epsilon, normalización de entradas, step size, número de pasos PGD, random start, clipping, checkpoint evaluado y modo eval().
 - PGD variados para ver si era problema del ataque.
 - Uso de AutoAttack y criterios de la literatura (Athalye et al.) sobre gradient masking para comprobar si la robustez observada es genuina o un artefacto del ataque.
- **8.3 Explicación y Cura:** Teoría de la "Desincronización Encoder-Prototipo". Mitigación mediante FT-E-M: fine-tuning del autoencoder incorporando también batches atacados con epsilon bajo. Comparación frente a FT-E y FT-0. Discusión como posible efecto de entrenamiento multi-epsilon/curricular, sin afirmarlo como prueba definitiva. Paper curriculum learning.

Capítulo 9. Conclusiones y Trabajo Futuro

- **Conclusiones:** Síntesis estructurada de los resultados frente a las 4 RQ
- **Limitaciones:**
 1. Las medidas de robustez son empíricas y attack-based, no certificadas.
 2. r-PGD depende de la configuración PGD y del procedimiento sweep + binary search.
 3. Las visualizaciones PCA son proyecciones 2D y no prueban por sí solas separación o solapamiento real en el espacio latente completo.
 4. La explicación de la anomalía FT-E es una hipótesis mecanicista apoyada por evidencia empírica, no una demostración formal.
 5. Limitación de computación (por eso PGD sin tantos pasos, sin PCA de AutoAttack)
- **Trabajo Futuro:**
 1. Certificación formal de radios de robustez.
 2. Evaluación con ataques adicionales y configuraciones más fuertes.
 3. Estudio sistemático de entrenamiento multi-epsilon/curricular.
 4. Aplicación de los patrones descubiertos al diseño de arquitecturas interpretables más robustas.

RESUMEN VISUAL DE LA NARRATIVA

1. **DIAGNÓSTICO:** ¿Por dónde se rompe el modelo limpio?
2. **INTERVENCIÓN:** ¿Qué pieza recupera la robustez?
3. **EXPLICACIÓN:** ¿Cómo lo repara mecánicamente?
4. **GENERALIZACIÓN:** ¿Es esto un patrón universal?

PREGUNTAS DEL TFG (Para referencia en la memoria)

- RQ1 (Diagnóstico): ¿Cómo se degrada internamente un modelo interpretable bajo ataque adversarial, y colapsa su justificación visual antes que su precisión de clasificación? (Se responde en el Cap. 4).
- RQ2 (Intervención): En arquitecturas basadas en prototipos, ¿existe un componente estructural específico (Autoencoder vs. Capas de Decisión) que asuma la carga de la robustez tras el adversarial fine-tuning? (Se responde en el Cap. 5).
- RQ3 (Mecánica): ¿Qué dinámicas topológicas en el espacio latente explican mecánicamente la adquisición de esta robustez o los posibles incrementos en la tasa de engaño del modelo (ICR)? (Se responde en el Cap. 6).
- RQ4 (Generalización): ¿Es el patrón de dependencia de la robustez un principio universal, o varía en función de cómo la arquitectura distribuye su carga semántica (contrastando B30 con ProtoVAE y SENN)? (Se responde en el Cap. 7).